MODELO:

Detecção de Fraudes em Transações PIX utilizando Teoria dos Grafos e Machine Learning

****** NÃO INCLUIR NOMES DOS AUTORES NEM DO CURSO *****

Resumo

Este projeto propõe investigar a aplicação de teoria dos grafos e métodos de machine learning para detecção de fraudes em transações PIX no contexto brasileiro. A pesquisa busca modelar transações financeiras como grafos, nos quais contas representam vértices e transferências representam arestas, permitindo a análise estrutural de comportamentos suspeitos. A motivação do estudo está relacionada ao crescimento de fraudes digitais associadas ao PIX e à necessidade de métodos mais inteligentes, interpretáveis e cientificamente fundamentados para identificação de padrões anômalos. Como parte do projeto, pretende-se desenvolver um dataset sintético de transações PIX fundamentado em análise exploratória de dados e em cenários inspirados em fraudes reais, como contas laranja, intermediários e lavagem em cadeia, ou, se possível, utilizar dados públicos disponibilizados pelo Banco Central do Brasil para complementar a pesquisa. Técnicas como Isolation Forest e DBSCAN serão utilizadas para análise de anomalias, além da aplicação de visualizações baseadas em grafos e heatmaps de risco (“grafos de calor”), buscando aumentar a interpretabilidade dos resultados. Espera-se contribuir cientificamente para as áreas de Inteligência Artificial, Ciência de Dados, Segurança Financeira e Análise de Redes Complexas.

Introdução

A crescente digitalização dos serviços financeiros no Brasil, impulsionada principalmente pela popularização do sistema PIX desenvolvido pelo Banco Central do Brasil, ampliou significativamente o volume e a velocidade das transações eletrônicas. Apesar dos avanços em praticidade e inclusão financeira, esse cenário também favoreceu o crescimento de fraudes digitais, como contas laranja, golpes de falso suporte bancário, clonagem de WhatsApp e esquemas de lavagem de dinheiro em cadeia. Nesse contexto, torna-se necessário investigar métodos computacionais capazes de identificar padrões anômalos de forma automatizada, interpretável e escalável.

Entre os principais conceitos utilizados no projeto estão teoria dos grafos, detecção de anomalias e *machine learning*. A teoria dos grafos permite representar sistemas financeiros como redes complexas, nas quais contas bancárias são modeladas como vértices e transações como arestas. Essa abordagem possibilita analisar relações estruturais entre usuários, identificar padrões de conectividade e detectar comportamentos suspeitos que frequentemente não são perceptíveis em modelos tabulares tradicionais. Métricas como grau, centralidade e intermediação (*betweenness centrality*) vêm sendo amplamente exploradas em pesquisas relacionadas à análise de redes financeiras e segurança cibernética.

Na área de Inteligência Artificial, técnicas de detecção de anomalias têm sido

utilizadas para identificar padrões incomuns em grandes volumes de dados. Métodos como Isolation Forest e DBSCAN destacam-se por sua aplicação em cenários com poucos dados rotulados, característica comum em problemas de fraude financeira. O estado da arte em pesquisa aponta um crescimento significativo de abordagens híbridas, combinando aprendizado de máquina com análise estrutural de grafos, permitindo não apenas detectar fraudes, mas compreender como elas se propagam dentro das redes financeiras.

No contexto de mercado e sociedade, instituições financeiras e empresas de tecnologia vêm investindo em sistemas inteligentes de monitoramento transacional para reduzir perdas financeiras e aumentar a segurança digital. Entretanto, muitos modelos utilizados atualmente ainda apresentam baixa interpretabilidade, dificultando compreender por que determinadas transações são classificadas como suspeitas. Além disso, parte das soluções comerciais depende de dados proprietários, o que limita a reprodutibilidade científica e o desenvolvimento acadêmico de novas abordagens.

Diante desse cenário, este projeto pretende pesquisar como a combinação entre teoria dos grafos, técnicas de detecção de anomalias e visualizações baseadas em heatmaps de risco (“grafos de calor”) pode contribuir para identificação e interpretação de fraudes em transações PIX, utilizando um dataset sintético fundamentado em análise exploratória de dados ou, se possível, dados públicos disponibilizados pelo Banco Central do Brasil.

1. Objetivos do Projeto

Objetivo Geral

- Investigar a aplicação conjunta de teoria dos grafos e métodos de *machine learning* para detecção e análise de fraudes em transações PIX no contexto brasileiro, buscando identificar padrões anômalos e aumentar a interpretabilidade dos resultados por meio de representações em grafos, visualizações tradicionais de redes e heatmaps de risco.

Objetivos Específicos

1. **Pesquisar** conceitos relacionados à teoria dos grafos, detecção de anomalias e fraudes financeiras digitais aplicadas ao sistema PIX.

2. **Desenvolver** ou, se possível, **utilizar** um dataset de transações PIX fundamentado em análise exploratória de dados e em padrões inspirados em fraudes reais.

3. **Modelar** as transações financeiras como grafos, representando contas bancárias como vértices e transferências financeiras como arestas.

4. **Aplicar** conceitos estudados em aula na disciplina de Teoria dos Grafos para construção, interpretação e visualização de redes financeiras.

5. **Extrair** métricas estruturais dos grafos, como grau, centralidade e intermediação (*betweenness centrality*), para caracterização de comportamentos financeiros.

6. **Aplicar** técnicas de detecção de anomalias, como Isolation Forest e DBSCAN, para identificação de padrões suspeitos.

7. **Analisar** diferentes perfis de fraude, como contas laranja, intermediários, coletores e estruturas de lavagem de dinheiro em cadeia.

8. **Comparar** abordagens baseadas em dados tabulares com abordagens fundamentadas em teoria dos grafos.

9. **Desenvolver** visualizações baseadas em grafos tradicionais e heatmaps de risco ("grafos de calor"), visando melhorar a interpretabilidade e identificação de "vértices quentes".

10. **Avaliar** a eficácia das técnicas aplicadas por meio de métricas de desempenho e análise dos resultados obtidos.

11. **Contribuir** para pesquisas nas áreas de Inteligência Artificial, Ciência de Dados, Segurança Financeira e Análise de Redes Complexas.

2. Procedimentos Metodológicos

A pesquisa será conduzida por meio de uma abordagem quantitativa e aplicada, utilizando conceitos de teoria dos grafos, análise exploratória de dados e técnicas de *machine learning* voltadas à detecção de anomalias em transações financeiras. Inicialmente, será realizada uma revisão bibliográfica sobre fraudes digitais no sistema PIX, análise de redes complexas e métodos computacionais utilizados na identificação de comportamentos suspeitos em sistemas financeiros, buscando compreender o estado da arte das soluções acadêmicas e práticas relacionadas ao tema.

Na etapa experimental, pretende-se desenvolver um dataset sintético de transações PIX fundamentado em padrões estatísticos e cenários inspirados em fraudes reais, como contas laranja, intermediários, golpes de falso suporte bancário, clonagem de WhatsApp e lavagem de dinheiro em cadeia. (Caso seja viável, também poderão ser utilizados dados públicos disponibilizados pelo Banco Central do Brasil para complementar a análise e aumentar o realismo da simulação.

As transações serão modeladas como grafos, nos quais os vértices representarão contas bancárias e as arestas representarão transferências financeiras. A partir dessa estrutura, pretende-se aplicar conceitos estudados na disciplina de Teoria dos Grafos, buscando compreender como métricas estruturais podem auxiliar na identificação de padrões suspeitos em redes financeiras. Serão utilizadas visualizações tradicionais de grafos para interpretação das conexões entre contas, além de representações baseadas em heatmaps de risco ("grafos de calor"), permitindo identificar vértices com maior probabilidade de comportamento anômalo.

Posteriormente, serão extraídas métricas de redes complexas, como grau, centralidade e intermediação (*betweenness centrality*), utilizadas como variáveis de entrada para algoritmos de detecção de anomalias. Para análise dos dados, serão aplicadas técnicas de *machine learning*, como Isolation Forest e DBSCAN, escolhidas por sua capacidade de identificar padrões incomuns em conjuntos de dados com baixa rotulação de fraude, cenário comum em problemas financeiros reais.

Os resultados serão avaliados por meio de métricas quantitativas de desempenho e comparações entre abordagens baseadas em dados tabulares e representações em grafos. Essa abordagem é adequada ao problema proposto porque fraudes financeiras geralmente apresentam padrões relacionais e comportamentais difíceis de serem observados em análises tradicionais exclusivamente tabulares, tornando a modelagem em grafos uma alternativa relevante para ampliar a interpretabilidade e compreensão das redes de fraude.

O projeto não envolverá coleta de dados pessoais reais, experimentação com seres humanos ou utilização de animais. Caso sejam utilizados dados públicos, serão respeitadas as diretrizes de privacidade e anonimização previstas pela legislação vigente, incluindo princípios relacionados à LGPD (Lei Geral de Proteção de Dados).

3. Cronograma

Atividades	**Meses**											
	1	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**	**11**	**12**
Revisão bibliográfica e fundamentação teórica	X	X										
Definição da metodologia e modelagem do problema		X	X									
Construção do dataset sintético PIX/seleção de dados públicos			X	X								
Análise exploratória de dados e validação do dataset				X	X							
Modelagem das transações em grafos					X	X						
Extração de métricas estruturais dos grafos						X	X					

Aplicação de técnicas de Machine Learning							X	X				
Desenvolvimento de visualizações em grafos e heatmaps								X	X			
Análise de perfis de fraude e interpretação dos resultados									X	X		
Comparação entre abordagem tabular e grafos										X	X	
Avaliação dos modelos e métricas de desempenho											X	X
Escrita, revisão e finalização do relatório científico											X	X

4. Referências Bibliográficas

Obs.: Algumas referências bibliográficas, cursos e materiais complementares poderão ser consultados e adicionados ao longo do desenvolvimento da Iniciação Científica, conforme a evolução da pesquisa, aprofundamento teórico e necessidades metodológicas do projeto.

Graph Theory. Graph Theory. 5. ed. Berlin: Springer, 2017.

Pattern Recognition and Machine Learning. Pattern Recognition and Machine Learning. New York: Springer, 2006.

Data Mining: Practical Machine Learning Tools and Techniques; Eibe Frank; Mark A. Hall. Data Mining: Practical Machine Learning Tools and Techniques. 3. ed. Burlington: Morgan Kaufmann, 2011.

Isolation Forest. In: Fei Tony Liu; Kai Ming Ting; Zhi-Hua Zhou. Isolation Forest. Proceedings of the 2008 IEEE International Conference on Data Mining. Pisa: IEEE, 2008.

DBSCAN. In: Martin Ester; Hans-Peter Kriegel; Jörg Sander; Xiaowei Xu. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. Portland: AAAI Press, 1996.

Banco Central do Brasil. PIX: arranjo de pagamentos instantâneos. Brasília: Banco Central do Brasil, 2024. Disponível em: https://www.bcb.gov.br/estabilidadefinanceira/pix. Acesso em: 16 maio 2026.

Networks, Crowds, and Markets; Jon Kleinberg. Networks, Crowds, and Markets: Reasoning About a Highly Connected World. New York: Cambridge University Press, 2010.

An Introduction to Statistical Learning; Daniela Witten; Trevor Hastie; Robert Tibshirani. An Introduction to Statistical Learning. 2. ed. New York: Springer, 2021.

Banco Central do Brasil. Relatório de Gestão do PIX. Brasília: Banco Central do Brasil, 2024. Disponível em: https://www.bcb.gov.br/. Acesso em: 16 maio 2026.

Udemy – Machine Learning e Data Science com Python de A a Z. Curso utilizado como apoio complementar para conceitos de aprendizado de máquina e análise de dados. Acesso em: 16 maio 2026.

Udemy – Teoria dos Grafos para Computação. Curso complementar para estudo de modelagem de redes, métricas estruturais e aplicações computacionais. Acesso em: 16 maio 2026.

Coursera – Machine Learning Specialization. Curso gratuito (modo auditoria) utilizado como apoio teórico em técnicas de aprendizado de máquina. Acesso em: 16 maio 2026.

Kaggle Learn – Intro to Machine Learning. Plataforma gratuita utilizada para estudos introdutórios de aprendizado de máquina e análise de dados. Acesso em: 16 maio 2026.
freeCodeCamp. Plataforma gratuita utilizada como apoio complementar em Python, ciência de dados e visualização de dados. Acesso em: 16 maio 2026.

***** TAMANHO MÍNIMO DE 2 PGS E MÁXIMO DE 10 PGS ******